

Desenvolvimento de uma Plataforma Web para Otimização de Rotas de Manutenção em Parques Eólicos Offshore Utilizando Métodos Meta-heurísticos

Klebiano Kennedy da Silva Lima^{1*}; Abdoulaye Aboubacari Mohamed²

¹ Engenheiro Eletricista. R. Cândido Fontoura, 575 - Jardim Boa Vista; 05583-070 São Paulo, São Paulo, Brasil

² Doutor em Economia Aplicada. Av. Pádua Dias, 13418-900, 11 - Agronomia, Piracicaba, São Paulo, Brasil

*autor correspondente: klebyano@gmail.com

Desenvolvimento de uma Plataforma Web para Otimização de Rotas de Manutenção em Parques Eólicos Offshore Utilizando Métodos Meta-heurísticos

Resumo

A energia eólica offshore, caracterizada pela instalação de turbinas eólicas no ambiente marítimo, tem despertado crescente interesse no Brasil e no cenário internacional, em virtude da busca por fontes de energia limpas, renováveis e com reduzido impacto ambiental e social. Apesar dos avanços realizados na construção e desenvolvimento de parques eólicos offshore visando à diminuição dos custos de implantação, a operação e manutenção (O&M) desses ativos permanece como um desafio significativo para a implementação de projetos tanto no Brasil quanto no exterior. Uma das estratégias mais eficazes para otimizar e, consequentemente, reduzir os custos de O&M reside no agendamento e roteamento das atividades de manutenção, aprimorando a alocação de recursos materiais e de pessoal qualificado. Este trabalho apresenta a implementação de algoritmos genéticos e meméticos aplicados ao roteamento das atividades de manutenção em aerogeradores de um complexo eólico offshore, considerando fatores como a trajetória e o tempo estimado de manutenção. Para viabilizar a visualização dos trajetos otimizados e a seleção de parâmetros para a execução da otimização, desenvolveu-se uma plataforma *web* e *APIs* (Application Programming Interfaces) para a comparação dos resultados e do tempo de execução. Os resultados obtidos demonstram que o genético apresenta um desempenho superior em termos de custo computacional em comparação ao algoritmo memético, tornando-se a escolha padrão na plataforma para otimizar rotas. A plataforma *web* desenvolvida proporciona uma redução significativa dos tempos de parada e otimização no uso de recursos, contribuindo para a diminuição dos custos operacionais dos parques eólicos offshore.

Palavras-chave: Energia Eólica Offshore; Otimização; Manutenção; Algoritmos Genéticos; Algoritmos Meméticos.

Development of a Web Platform for Optimizing Maintenance Routes in Offshore Wind Farms Using Metaheuristic Methods

Abstract

Offshore wind energy, characterized by the installation of wind turbines in the marine environment, has been garnering increasing interest in Brazil and internationally due to the pursuit of clean, renewable energy sources with reduced environmental and social impact. Despite advances made in the construction and development of offshore wind farms aiming to reduce installation costs, the operation and maintenance (O&M) of these assets remain significant challenges for project implementation both in Brazil and abroad. One of the most effective strategies to optimize and consequently reduce O&M costs lies in the scheduling and routing of maintenance activities, improving the allocation of material resources and qualified personnel. This work presents the implementation of genetic and memetic algorithms applied to the routing of maintenance activities in wind turbines of an offshore wind complex, considering factors such as trajectory and estimated maintenance time. To enable the visualization of optimized routes and the selection of parameters for executing the optimization, a web platform and APIs (Application Programming Interfaces) were developed for comparing the results and execution time. The results obtained demonstrate that the genetic algorithm presents superior performance in terms of computational cost compared to the memetic algorithm, becoming the default choice in the platform for route optimization. The developed web platform provides a significant reduction in downtime and optimizes resource usage, contributing to the decrease of operational costs of offshore wind farms.

Keywords: Offshore Wind Energy; Optimization; Maintenance; Genetic Algorithms; Memetic Algorithms.

Introdução

A energia eólica offshore no Brasil apresenta-se como uma fonte promissora de energia renovável, detendo um imenso potencial a ser explorado. As extensas áreas litorâneas do país oferecem condições ideais para a implantação de projetos eólicos, com estimativas apontando para uma capacidade total de geração de aproximadamente 3 TW e mais de 14.000 TWh de energia anualmente, equivalente a 20 vezes a capacidade total instalada do Brasil em 2020 (Azevedo et al., 2020). Até 2024, mais de 75 projetos eólicos offshore aguardavam aprovação de licenciamento ambiental federal pelo IBAMA (Instituto Brasileiro do Meio Ambiente e dos Recursos Naturais Renováveis), totalizando uma expectativa de geração superior a 180 GW (IBAMA, 2022).

Entretanto, a construção, operação e manutenção desses ativos representam desafios cruciais para assegurar a sustentabilidade da geração e a disponibilidade energética. A operação e manutenção (O&M) de parques eólicos constitui uma parcela significativa dos custos da energia gerada, podendo inviabilizar a implantação de projetos específicos. No contexto da energia eólica offshore, esses custos são ainda mais elevados quando comparados à eólica onshore, onde os parques são implementados em terra. Especificamente, na eólica offshore, os custos de O&M representam cerca de 23% do custo total de investimento, principalmente devido às condições ambientais de alta salinidade às quais os aerogeradores estão expostos (Ren et al., 2021). Em contrapartida, nos complexos eólicos onshore, os custos de O&M correspondem a apenas 5% do investimento total, impactando menos no LCOE (custo nivelado de energia).

Adicionalmente, fatores como o uso de equipamentos e pessoal altamente especializados, incluindo frotas de embarcações e técnicos treinados, aumentam os custos de manutenção na energia offshore. O incremento da potência nominal dos aerogeradores também implica em maior necessidade de manutenção corretiva em diversos subsistemas, especialmente nos sistemas elétricos e eletrônicos (Faulstich et al., 2011). As condições climáticas adversas do ambiente marítimo agravam esses desafios, aumentando o tempo de indisponibilidade dos aerogeradores e resultando em maiores perdas de energia.

Para mitigar esses obstáculos, diversos métodos têm sido pesquisados e testados em diferentes cenários, considerando parâmetros como distância de trajeto, custo de peças de reposição e consumo de combustível, com o objetivo de identificar o modelo mais eficiente de agendamento e roteamento de manutenção em parques eólicos offshore (Zhang, 2014). A tarefa de definir uma programação de manutenção e roteamento de aerogeradores para otimizar o atendimento em menor tempo assemelha-se ao Problema do Caixeiro Viajante (PCV), no qual se busca determinar o percurso de menor custo ou distância que permite visitar

um conjunto de cidades exatamente uma vez. No caso de um complexo eólico offshore, o conjunto para execução da otimização é composto apenas pelos aerogeradores com falhas que necessitam de manutenção imediata.

Diversos algoritmos têm sido desenvolvidos e aplicados para encontrar soluções ótimas em problemas de roteamento e agendamento na área de otimização combinatória, que se dedica à seleção das combinações ideais de elementos a partir de um conjunto finito. Entre os algoritmos utilizados para solucionar esse tipo de problema destacam-se os algoritmos genéticos (AG), algoritmos meméticos, redes neurais artificiais e a otimização por colônia de formigas (OCF). Na otimização de rotas de manutenção em parques eólicos offshore, podem ser considerados objetivos simples ou complexos, como a distância percorrida pela embarcação, custos e capacidades de pessoal e material, restrições sazonais e disponibilidade de embarcações. As variáveis a serem utilizadas na otimização dependem, principalmente, da quantidade de dados disponíveis e das necessidades computacionais (Stock-Williams e Swamy, 2019).

Recentemente, diversos estudos têm abordado a otimização das atividades de manutenção em parques eólicos offshore, levando em consideração uma variedade de variáveis de entrada e modelos de solução. Entre esses, a programação linear inteira mista tem sido amplamente utilizada devido à sua rapidez e maior precisão, especialmente em problemas envolvendo um pequeno número de aerogeradores (Kovacs et al., 2011). Por outro lado, alguns estudos focam na otimização de custos, adicionando variáveis como o número de trabalhadores disponíveis, capacidade de carga das embarcações, peso máximo de peças sobressalentes, número de horas úteis disponíveis e possíveis penalidades decorrentes de condições climáticas (Dai et al., 2015).

Além disso, muitos trabalhos exploram o uso de métodos heurísticos, demonstrando sua superioridade em comparação aos métodos exatos quando o número de aerogeradores com falha é elevado. Um exemplo disso é a aplicação de um algoritmo de agrupamento baseado em correspondência, que se mostrou mais eficaz do que otimizadores comerciais, como o *IBM CPLEX*, em certos cenários (Dawid et al., 2017). A utilização de modelos heurísticos híbridos também tem se destacado, como demonstrado por Fan et al. (2019), onde uma combinação de otimização por enxame de partículas e o algoritmo de busca por alcateia de lobos foi implementada, resultando em reduções significativas nos custos de materiais e mão de obra em um complexo eólico com múltiplas bases e parques.

Esses estudos ressaltam a importância de modelos avançados para a gestão eficiente da manutenção em parques eólicos offshore, com foco na redução de custos e melhoria da logística de operações.

Este trabalho oferece uma contribuição relevante ao combinar algoritmos genéticos e meméticos para otimizar o roteamento de manutenção em parques eólicos offshore. Enquanto a maior parte da literatura concentra-se na aplicação de um único tipo de meta-heurística, este trabalho realiza uma comparação detalhada entre os dois algoritmos, considerando tanto a eficiência quanto o tempo de execução de cada um. O desenvolvimento de uma plataforma *Web* interativa, que permite aos usuários personalizar parâmetros de otimização e visualizar rotas otimizadas em tempo real, introduz uma inovação significativa no gerenciamento de ativos eólicos. A inclusão de um controle adaptativo dos parâmetros dos algoritmos elimina a necessidade de ajustes manuais, proporcionando uma experiência mais fluida e eficiente para os operadores e técnicos, e aprimorando a eficácia na gestão de manutenção.

Além disso, foram implementados algoritmos genéticos e meméticos para otimizar o planejamento e o roteamento de manutenção em um complexo eólico localizado na costa nordeste do Brasil, utilizando dados de distância e tempo de manutenção como variáveis de entrada. Para facilitar a visualização e a execução dos testes, foi desenvolvida uma plataforma *Web* interativa com uma *API* para consulta e interação. O objetivo principal é testar e validar os métodos de otimização propostos, avaliando os ganhos operacionais e o desempenho da aplicação, ao mesmo tempo em que se simplifica a identificação de potenciais problemas pelos usuários. Com isso, o trabalho contribui diretamente para a redução de custos operacionais e para a otimização logística em complexos eólicos offshore.

Materiais e Métodos

Métodos Meta-heurísticos

Os métodos meta-heurísticos são técnicas de otimização que buscam soluções aproximadas para problemas complexos, principalmente aqueles classificados como NP-difíceis, onde uma solução exata é computacionalmente inviável. Diferente dos algoritmos tradicionais que exploram todas as possibilidades, os meta-heurísticos utilizam estratégias inteligentes de busca para encontrar boas soluções em um tempo computacional aceitável (Karimi-Mamaghan et al., 2022).

A otimização por algoritmos genéticos é uma técnica meta-heurística desenvolvida na década de 1970 (Holland, 1975), inicialmente proposta pelo cientista da computação norte-americano Dr. John Holland. Essa abordagem busca replicar, de forma simplificada, os processos de evolução natural observados na biologia, onde indivíduos mais adaptados têm maior probabilidade de transmitir suas características para as próximas gerações. Os algoritmos genéticos utilizam mecanismos como seleção, cruzamento e mutação para

explorar o espaço de soluções de um problema, buscando encontrar soluções ótimas ou próximas do ótimo.

No contexto do Problema do Caixeiro Viajante (PCV), os algoritmos genéticos têm sido amplamente aplicados devido à natureza combinatória e complexa do problema. O PCV consiste em encontrar o menor percurso possível que permite a um vendedor passar por um conjunto de cidades exatamente uma vez e retornar à cidade de origem. Sendo um problema classificado como NP-difícil, a resolução exata do PCV torna-se inviável para conforme o número de cidades incrementa, pois o tempo computacional necessário cresce exponencialmente.

A aplicação de algoritmos genéticos ao PCV oferece uma alternativa heurística eficiente para encontrar soluções aproximadas em um tempo computacional razoável. Ao simular processos evolutivos, a população de soluções (rotas) é iterativamente aprimorada, onde as rotas de melhor desempenho têm maior probabilidade de contribuir para a formação de novas rotas nas gerações subsequentes. Esse processo permite que o algoritmo convirja para soluções de alta qualidade, mesmo em espaços de busca extensos e complexos, evidenciando a eficácia dos algoritmos genéticos na otimização de problemas combinatórios.

A otimização por algoritmos meméticos é uma extensão dos algoritmos genéticos, desenvolvida para combinar as vantagens da evolução natural com técnicas de busca local mais refinadas (Moscato, 1989). Esta abordagem híbrida explora os processos de evolução natural observados na biologia, onde indivíduos mais adaptados têm maior probabilidade de transmitir suas características para as próximas gerações, e aprimora essas soluções por meio de técnicas de otimização local, que ajusta e refina as soluções encontradas. Assim, o algoritmo memético combina seleção, cruzamento e mutação com uma busca local intensiva para explorar mais eficientemente o espaço de soluções.

Nos algoritmos meméticos, uma técnica utilizada como busca local e implementada neste trabalho é a *2-opt*, onde a ideia central é eliminar cruzamentos ou inversões ineficientes na rota. O algoritmo faz isso trocando dois segmentos não adjacentes da rota para minimizar a função objetivo. Este processo é repetido até que não seja mais possível melhorar a rota ou até que o número de iterações máximas foi alcançado. O fluxograma do algoritmo implementado neste trabalho pode ser visualizado na Figura 1.




Figura 1. Fluxograma do algoritmo genético e memético.

Fonte: Dados originais da pesquisa.

Area de estudo

O complexo eólico *offshore*, composto por 212 aerogeradores, utilizado para a aplicação dos algoritmos de roteirização e planejamento das atividades de manutenção, está situado em uma área marítima nas proximidades da cidade de Areia Branca, no estado do Rio Grande do Norte. A escolha desse complexo eólico foi baseada em projetos que aguardavam aprovação ambiental pelo IBAMA em 2024. Cada aerogerador terá uma potência máxima projetada de 14 MW, resultando em uma capacidade total instalada de 3 GW para o complexo. Como o empreendimento ainda se encontra em fase de desenvolvimento, o ponto de partida das embarcações foi definido como o local mais próximo da costa, identificado como Doca, conforme ilustrado na Figura 2.



Figura 2. Coordenadas geográficas dos aerogeradores do complexo eólico e ponto de partida das embarcações.

Fonte: Dados originais da pesquisa.

Dados de falha em aerogeradores e suas características

Foram utilizados dados do programa WMEP (Scientific Measurement and Evaluation Programme, do inglês Programa de medição e avaliação científica) (Faulstich et al., 2011), onde foi realizada uma avaliação entre 1989 e 2006 por diversos agentes da indústria eólica que permitiu a coleta de dados sobre os parâmetros de confiabilidade dos aerogeradores, como o *mean time to repair* [MTTR], ou tempo médio de reparo, e o *mean time between failure* [MTBF], ou tempo médio entre falhas. Essa avaliação foi implementada com base em uma amostra de aproximadamente 1500 aerogeradores em diferentes cenários operacionais e divididos entre falhas leves e graves e por componente do aerogerador. A Tabela 1 apresenta os valores de Taxa de Falha Anual e Tempo de Parada em Dias para cada componente dos aerogeradores, categorizados de acordo com o nível de severidade dessas falhas.

Tabela 1. Valores de taxa de falha anual e tempo de falha para cada componente do aerogerador e subdividido por severidade.

Componente	Severidade	Taxa de falha anual	Tempo de falha em dias
Sistema elétrico	Leve	0,45	0,17
Sistema elétrico	Grave	0,12	6,55
Controlador eletrônico	Leve	0,34	0,15
Controlador eletrônico	Grave	0,09	6,87
Sensores	Leve	0,2	0,16
Sensores	Grave	0,05	6,41
Sistema hidráulico	Leve	0,18	0,18
Sistema hidráulico	Grave	0,05	5,93
Sistema de orientação	Leve	0,13	0,16
Sistema de orientação	Grave	0,05	10,09
Cubo do rotor	Leve	0,12	0,18
Cubo do rotor	Grave	0,06	10,93
Freio mecânico	Leve	0,11	0,16
Freio mecânico	Grave	0,03	13,08
Pás eólicas	Leve	0,09	0,18
Pás eólicas	Grave	0,02	11,86
Multiplicadora	Leve	0,06	0,17
Multiplicadora	Grave	0,03	18,38
Gerador	Leve	0,07	0,15
Gerador	Grave	0,05	14,34
Suportes e invólucro	Leve	0,08	0,14
Suportes e invólucro	Grave	0,02	28,01
Transmissão mecânica	Leve	0,03	0,17
Transmissão mecânica	Grave	0,02	15,47

Fonte: Faulstich et al. (2011).

Com os dados de tempo de falha por severidade e por componente dos aerogeradores, foi possível desenvolver a função objetivo, utilizada para avaliar as rotas de manutenção no complexo eólico. Essa função tem como base a minimização dos valores normalizados da distância percorrida pelas embarcações e do tempo de parada estimado para cada aerogerador, conforme descrito na eq. (1).

$$\text{Objetivo} = \min \left(\sum_{j=1}^m \sum_{i=1}^m d_{ij} x_{ij} + \sum_{j=1}^m \sum_{i=1}^m t_{ij} x_{ij} \right) \quad (1)$$

onde c_{ij} é a distância entre os aerogeradores, t_{ij} é o tempo de parada estimado entre os aerogeradores e x_{ij} é uma variável de decisão binária que indica se o ponto i está diretamente conectado ao ponto j em uma rota ou percurso. Para a comparação entre modelos, adotou-se o solver CBC (Coin-or Branch and Cut) como principal ferramenta de otimização. O CBC é um solver de código aberto amplamente utilizado na resolução de problemas de programação linear e inteira, destacando-se pela eficiência e flexibilidade. Ele emprega métodos avançados, como Branch-and-Cut e técnicas de geração de cortes, permitindo a obtenção de soluções ótimas em um tempo computacional reduzido (Forrest e Lougee-Heimer, 2005).

Resultados e Discussão

Modelagem de problemas e rotas

A reprodutibilidade é fundamental na comparação de modelos distintos, como os algoritmos genético e memético. Para padronizar o processo comparativo, foram desenvolvidas seis rotas distintas a serem utilizadas nos experimentos. Essas rotas contêm, respectivamente, 100, 40, 20, 15, 10 e 5 aerogeradores selecionados aleatoriamente, assegurando que em cada conjunto haja pelo menos um aerogerador com uma falha classificada como grave em componentes distintos, como a multiplicadora e o freio mecânico. As rotas empregadas neste trabalho estão detalhadas na Tabela 2, os aerogeradores com severidade do tipo grave foram ordenados do número 1 ao 212, de acordo com a quantidade total de aerogeradores no complexo eólico.

Tabela 2. Problemas padronizados e selecionados para comparação entre algoritmos.

Problema	Número de aerogeradores	Aerogeradores selecionados em falha grave	Componentes
1	100	197 e 199	Cubo do rotor e freio mecânico
2	40	05 e 18	Multiplicadora e transmissão mecânica

3	20	47	Controlador eletrônico
4	15	45 e 118	Controlador eletrônico e multiplicadora
5	10	11	Freio mecânico
6	5	120	Sistema hidráulico

Fonte: Resultados originais da pesquisa.

Seleção de parâmetros em algoritmos genéticos e meméticos

Os parâmetros empregados na execução do algoritmo genético, como tamanho da população (ρ), taxa de mutação (α), e número de gerações (η), são amplamente estudados e variam conforme os objetivos e diferentes problemas de otimização (Alibrahim e Ludwig, 2021). Para selecionar os valores ideais de ρ , α e η , foi implementado um algoritmo de *grid search*, onde é explorado todas as combinações possíveis de parâmetros predefinidos, com intervalos e faixas distintos. Foram realizadas execuções para cada conjunto de parâmetros nos problemas exemplificados na Tabela 2, selecionando aqueles com menor tempo de execução e melhor convergência. Os valores e intervalos testados no *grid search* para cada parâmetro estão detalhados na Tabela 3.

Tabela 3. Parâmetros do algoritmo genético e memético utilizados na busca com *grid search*.

Parâmetro	Símbolo	Valor mínimo	Valor máximo	Degrau
Taxa de mutação	α	0,1	0,6	0,1
Tamanho da população	ρ	50	200	50
Número de gerações	η	10	50	10

Fonte: Resultados originais da pesquisa.

Os parâmetros ótimos dos algoritmos genético e memético, identificados para cada problema analisado, são apresentados nas Tabelas 4 e 5, respectivamente. Essas tabelas destacam a heurística aplicada, a soma das distâncias percorridas e dos tempos de parada, além do tempo médio de execução de cada busca realizada por meio do *grid search*.

Tabela 4. Parâmetros ótimos do algoritmo genético identificados por busca *grid search*.

Problema	α	ρ	η	Heurística	Tempo médio de execução (segundos)
1	0,1	50	50	31,3488	12,4946
2	0,1	100	170	12,7740	6,2159
3	0,1	100	150	4,8397	3,4166
4	0,1	100	150	5,3617	2,6897
5	0,2	50	50	4,6829	0,5458
6	0,4	50	50	4,6051	0,3733

Fonte: Resultados originais da pesquisa.

Tabela 5. Parâmetros ótimos do algoritmo memético identificados por busca *grid search*.

Problema	α	ρ	η	Heurística	Tempo médio de execução (segundos)
1	0,1	50	30	24,2918	304,9923
2	0,1	150	50	8,3827	318,8769
3	0,3	50	10	4,5845	10,6154
4	0,1	50	10	5,2777	5,7874
5	0,2	50	10	4,6829	1,4654
6	0,2	50	10	4,6051	0,4073

Fonte: Resultados originais da pesquisa.

Na Tabela 6, são apresentados os dados referentes à heurística e ao tempo médio de execução obtidos com o solver CBC, considerando um limite máximo de 1200 segundos. Esse tempo limite foi atingido nos problemas 1 e 2, que envolvem 100 e 40 aerogeradores, respectivamente. Já as Tabelas 7 e 8 mostram a comparação percentual entre os resultados obtidos pelos algoritmos genético, memético e solver CBC, auxiliando na seleção do algoritmo mais eficiente com base no tempo de execução e na eficácia da heurística aplicada.

Tabela 6. Desempenho da heurística e tempo médio de execução do solver CBC.

Problema	Heurística	Tempo médio de execução (segundos)
1	11,0917	>1200
2	8,2054	>1200
3	4,5845	8,65
4	5,2777	2,87
5	4,6829	1,46
6	4,6051	0,07

Fonte: Resultados originais da pesquisa.

Tabela 7. Comparação entre heurística e tempo médio de execução entre o algoritmo genético memético.

Problema	Diferença na Heurística (%)	Diferença no tempo médio de execução (%)	Melhor algoritmo
1	22,51%	2340,99%	Genético
2	34,38%	5030,02%	Genético
3	5,27%	210,70%	Genético
4	1,57%	115,17%	Genético
5	0%	168,49%	Genético
6	0%	9,11%	Genético

Fonte: Resultados originais da pesquisa.

Tabela 8. Comparação entre heurística e tempo médio de execução entre o melhor algoritmo e o solver CBC.

Problema	Diferença na Heurística (%)	Diferença no tempo médio de execução (%)	Melhor algoritmo
1	64,62%	9504,15%	Genético
2	35,76%	19205,33%	Genético
3	5,57%	153,18%	Genético
4	1,59%	6,70%	Genético
5	0%	167,50%	Genético
6	0%	81,25%	CBC

Fonte: Resultados originais da pesquisa.

Com o objetivo de generalizar as aplicações para todos os problemas de entrada solicitados pelo usuário final na plataforma *Web*, foram selecionados parâmetros específicos para o algoritmo genético. Para problemas envolvendo 15 ou mais aerogeradores, os parâmetros foram fixados em $\alpha = 0,1$, $\rho = 100$ e $\eta = 150$. Para problemas com 14 ou menos aerogeradores, os parâmetros foram ajustados para $\alpha = 0,2$, $\rho = 50$ e $\eta = 50$.

Analogamente, para o algoritmo memético, os parâmetros selecionados foram $\alpha = 0,1$, $\rho = 150$ e $\eta = 50$ para problemas com 40 ou mais aerogeradores, e $\alpha = 0,2$, $\rho = 50$ e $\eta = 10$ para problemas com 39 ou menos aerogeradores.

O tempo de execução significativamente maior do algoritmo memético, em comparação ao algoritmo genético, está alinhado com os achados de Garg (2010). Nesses resultados, o algoritmo genético se destaca por apresentar maior robustez e menor sensibilidade a variações nas condições do problema, resultando em um tempo de execução mais eficiente para casos de menor complexidade. Por outro lado, o algoritmo memético, apesar de ser mais eficaz em problemas de maior complexidade e com grande volume de dados, sofre com tempos de execução elevados devido à sua busca local intensiva. Essa mesma tendência é observada na comparação com o solver CBC, em que, para problemas envolvendo mais de 25 aerogeradores, o tempo de execução do CBC também se torna alto, limitando sua aplicação em plataformas *Web*, onde o tempo de resposta é um requisito essencial.

O controle adaptativo dos parâmetros para aprimorar a experiência do usuário foi implementado no processamento da *API*, eliminando a necessidade de inserção manual de parâmetros na plataforma *Web*. Todos os experimentos de manipulação, tratamento de dados e resultados computados neste trabalho foram realizados utilizando a biblioteca *Pandas* na versão 1.5.0 em um *notebook* equipado com processador *Intel® Core™ i5* de 10ª geração, 20 GB de memória *RAM* e *SSD* de 1 TB. O sistema operacional utilizado foi o *Windows 11 Home Single Language*, versão 22H2, e a linguagem de programação adotada foi o *Python 3.10.9*.

A coleta dos dados de entrada e a visualização dos dados de saída para os algoritmos foram realizadas por meio de uma plataforma *Web* desenvolvida com a biblioteca *React 18.2.0* na linguagem de programação *JavaScript*. O banco de dados selecionado para armazenar as tabelas de posicionamento geográfico, como a latitude e longitude de cada aerogerador, múltiplos sistemas e tempo de parada por falha foi o *PostgreSQL* na versão 15.4.0. O acesso aos dados foi realizado através de requisições *HTTP (HyperText Transfer Protocol)* para uma *API* desenvolvida utilizando a biblioteca *FastAPI* na versão 0.112.2.

A implementação da solução para o Problema 2, que abrange a otimização de rotas para 40 aerogeradores, está disponível para visualização na plataforma *Web*, conforme apresentado na Figura 3, onde é exibido um mapa detalhado que ilustra a rota otimizada gerada pelo algoritmo genético, acompanhada de uma demonstração da rota e cada um dos aerogeradores em ordem.

A interface completa da plataforma, incluindo todos os campos de entrada preenchidos pelo usuário, está detalhada na Figura 4 do apêndice. Esta figura evidencia a disposição intuitiva dos elementos da interface, facilitando a interação do usuário com o sistema. A plataforma não apenas simplifica o processo de inserção de dados, mas também aprimora a experiência do usuário ao fornecer visualizações claras dos resultados, permitindo uma análise eficiente das rotas otimizadas e dos parâmetros envolvidos na solução do problema.




Figura 3. Mapa e descrição da rota otimizada para problema 02 com 40 aerogeradores após execução de algoritmo genético.

Fonte: Resultados originais da pesquisa.

Considerações finais

Neste trabalho, foi desenvolvida uma plataforma Web para a otimização de rotas de manutenção em parques eólicos offshore, integrando métodos meta-heurísticos, como os algoritmos genético e memético. A implementação e a comparação dos algoritmos evidenciaram a eficácia do algoritmo genético, especialmente devido à sua simplicidade e menor custo computacional em comparação com o algoritmo memético e a solução exata obtida pelo solver CBC. A plataforma proposta fornece uma solução eficiente para o roteamento de manutenção, permitindo uma redução significativa nos tempos de parada e otimizando o uso de recursos, o que é essencial para reduzir os altos custos operacionais em parques eólicos *offshore*.

Embora o algoritmo memético tenha demonstrado um desempenho superior em alguns cenários específicos, sua maior complexidade e o tempo de execução prolongado inviabilizaram seu uso como padrão na plataforma. O controle adaptativo dos parâmetros implementado na *API* da plataforma possibilita uma maior flexibilidade na resolução de diferentes problemas de otimização, eliminando a necessidade de intervenção manual para ajustar os parâmetros.

No futuro, recomenda-se a implementação e comparação de novos algoritmos, como colônia de formigas ou otimização por enxame de partículas, além de melhorias na interface do usuário e na integração da plataforma com outros sistemas de gestão de ativos. A expansão da capacidade de simulação para condições climáticas variáveis também pode aumentar a robustez da solução. O desenvolvimento contínuo desta plataforma contribuirá para a viabilidade econômica e operacional dos parques eólicos *offshore* no Brasil, promovendo a geração de energia renovável de forma mais eficiente e sustentável.

Referências

ALIBRAHIM, Hussain; LUDWIG, Simone A. 2021. Hyperparameter optimization: Comparing genetic algorithm against grid search and bayesian optimization. In: 2021 IEEE Congress on Evolutionary Computation (CEC). 1551-1559.

Azevedo, S. S. P. D.; Junior, A. O. P.; Silva, N. F. D.; Araújo, R. S. B. D.; & Júnior, A. A. C. 2020. Assessment of offshore wind power Potential along the Brazilian coast. *Energies*. 13(10). 2557.

Dai, L., Stålhane, M., & Utne, I. B. 2015. Routing and scheduling of maintenance fleet for offshore wind farms. *Wind Engineering*, 39(1), 15–30.

Dawid, R., McMillan, D., & Revie, M. 2017. Heuristic algorithm for the problem of vessel routing optimisation for offshore wind farms. *The Journal of Engineering*, 2017 (13), 1159–1163.

Fan, D., Ren, Y., Feng, Q., Zhu, B., Liu, Y., & Wang, Z. 2019. A hybrid heuristic optimization of maintenance routing and scheduling for offshore wind farms. *Journal of Loss Prevention in the Process Industries*, 62, 103949.

Faulstich, S.; Hahn, B.; & Tavner, P. J. 2011. Wind turbine downtime and its importance for offshore deployment. *Wind energy*. 14(3). 327-337.

FORREST, John; LOUGEE-HEIMER, Robin. 2005. CBC user guide. In: *Emerging theory, methods, and applications*. INFORMS. p. 257-277.

Garg, P. 2010. A Comparison between Memetic algorithm and Genetic algorithm for the cryptanalysis of Simplified Data Encryption Standard algorithm. *arXiv preprint arXiv:1004.0574*.

Holland, J. 1976. *Adaptation in natural and artificial systems*, 529.

Instituto Brasileiro do Meio Ambiente e dos Recursos Naturais Renováveis [IBAMA]. 2022. Mapas de projetos em licenciamento - Complexos Eólicos Offshore. Disponível em: <https://www.gov.br/ibama/pt-br/assuntos/laf/consultas/mapas-de-projetos-em-licenciamento-complexos-eolicos-offshore>. Acesso em: 05 Agosto. 2024

Karimi-Mamaghan, M., Mohammadi, M., Meyer, P., Karimi-Mamaghan, A. M., & Talbi, E. G. 2022. Machine learning at the service of meta-heuristics for solving combinatorial optimization problems: A state-of-the-art. *European Journal of Operational Research*, 296(2), 393-422.

Kovacs, A., Erdős, G., Viharos, Z. J., & Monostori, L. 2011. A system for the detailed scheduling of wind farm maintenance. *CIRP Annals-Manufacturing Technology*, 60(1), 497–501

Moscato, P. (1989). On evolution, search, optimization, genetic algorithms and martial arts: Towards memetic algorithms. *Caltech concurrent computation program, C3P Report*, 826, 37.

Ren, Z.; Verma, A. S.; Li, Y.; Teuwen, J. J.; & Jiang, Z. 2021. Offshore wind turbine operations and maintenance: A state-of-the-art review. *Renewable and Sustainable Energy Reviews*. 144. 110886.

Stock-Williams, C.; & Swamy, S. K. 2019. Automated daily maintenance planning for offshore wind farms. *Renewable Energy*. 133. 1393-1403.

Zhang, Z. Y. 2014. Scheduling and routing optimization of maintenance fleet for offshore wind farms using Duo-ACO. *Advanced materials research*. 1039. 294-301.

Apêndice




Figura 4. Página Web completa com interface gráfica e parâmetros imputados pelo usuário.
Fonte: Resultados originais da pesquisa.